

Algoritmo Evolucionário para a determinação do  
ponto mínimo global da função de Ackley  
Tópicos Avançados em IA - Projeto 1

Carlos Henrique <sup>\*</sup>      Cristiano Oliveira<sup>†</sup>      Lucas Cavalcanti<sup>‡</sup>  
Roberto Fernandes<sup>§</sup>

Maio de 2018

---

<sup>\*</sup>chcp@cin.ufpe.br

<sup>†</sup>cso@cin.ufpe.br

<sup>‡</sup>lhcs@cin.ufpe.br

<sup>§</sup>rcf6@cin.ufpe.br

# Sumário

<b>Sumário</b>	<b>2</b>
1 Metodologia	3
1.1 Primeira abordagem: estratégia ingênua	3
1.2 Segunda abordagem	4
1.3 Terceira abordagem: estratégia auto-adaptativa	4
2 Resultados	5
2.1 Primeira abordagem	5
2.2 Segunda abordagem	6
2.3 Terceira abordagem	6

## Objetivo

O projeto tem como objetivo utilizar de algoritmos evolucionários para a determinar o ponto mínimo global da função de Ackley, enunciada na *equação 1*, do qual seu gráfico pode ser observado na figura , quando  $n = 2$ .

$$F(x) = -C_1 \times \exp(-C_2 \times \sqrt{\frac{1}{N} \sum_{i=1}^N X_i^2}) - \exp(\frac{1}{N} \times \sum_{i=1}^N \cos(C_3 \times X_i)) + C_1 + \exp(1) \quad (1)$$




Figura 1 – Forma da função de Ackley em 2 dimensões

Por conta da existência de vários mínimos locais na função, foram utilizadas três estratégias evolutivas: uma estratégia ingênua somente com mutação, uma estratégia com variância para cada dimensão e uma estratégia aumentando a população e utilizando crossover.

## 1 Metodologia

### 1.1 Primeira abordagem: estratégia ingênua

A primeira estratégia foi a mais ingênua e tinha como objetivo servir como comparação para as próximas estratégias a serem implementadas. Nessa estratégia a população consistia em apenas um indivíduo, iniciado aleatoriamente com um valor entre -15 e 15, sem nenhum crossover e apenas

com mutação. Nessa estratégia cada indivíduo representa um valor em uma dimensão, assim cada indivíduo é composto por um vetor de 30 posições, esses pontos também obedeciam a restrição de ter módulo menor que 15. Com esses pontos o fitness de um indivíduo pode ser calculado aplicando esses pontos na função de Ackley.

Aplica-se na equação 1 como enunciado acima:

- $N = 30$
- $-15 \leq X_i \leq 15$

Como a estratégia ingênua só utiliza o operador de mutação, esse operador tem que ser capaz de explorar e explotar no espaço de soluções. Para isso a mutação consistia em alterar o valor de um ponto, adicionando uma alteração de acordo com uma distribuição normal, com média 0 e desvio padrão.  $\sigma$ . O fator que determina se a mutação permanece no indivíduo é a aplicação da função de fitness no indivíduo após a mutação. Para permitir que a mutação explorasse e explotasse de acordo com andamento do algoritmo foi utilizado a regra do 1/5 para alterar o valor de  $\sigma$ . Essa regra consiste em aumentar o valor de  $\sigma$ , se a taxa de mutação é maior que 1/5, para explorar, diminuir o valor de  $\sigma$ , se a taxa de mutação é menor que 1/5, para explotar. Na implementação da estratégia a equipe escolheu alterar o valor de  $\sigma$  em 20%.

A abordagem ingênua executava até um máximo de 20.000 gerações, ou até que não houvesse nenhuma alteração no fitness nas últimas 10.000 gerações, para deixar a estratégia mais suscetível a escapar de mínimos locais.

## 1.2 Segunda abordagem

A segunda estratégia foi uma melhoria na primeira estratégia, somente colocando o desvio padrão  $\sigma$  para cada gene do indivíduo ao invés de todo o genótipo. Dessa forma após cada mutação de gene é avaliado se a mutação irá permanecer, dado se a seu fitness melhorou.

$$gene_i = gene_i + N(0, \sigma_i) \quad (2)$$

## 1.3 Terceira abordagem: estratégia auto-adaptativa

A terceira estratégia foi feita para uma população de N indivíduos, nos testes foram utilizados 100. igualmente com a estratégia anterior cada genótipo é representado por um vetor de 30 características, podendo assumir valores reais de -15 a 15, e para cada gene é associado um passo de mutação  $\sigma$ . A abordagem começa com a seleção de país, onde foi adotado o método da roleta selecionando  $2 * N$ . Posteriormente para cada casal de país é gerado um único filho escolhendo aleatoriamente genes e passos de mutação dos genótipos país.

Todo filho gerado no processo de cross-over é passado pelo processo de mutação, onde primeiramente cada passo de mutação tem seu valor atualizado descrito pela fórmula a seguir:

$$\sigma = \sigma * \exp(\tau * N(0.0, 1)), \tau = \frac{1}{\sqrt{30}} \quad (3)$$

Posteriormente, cada gene é mutado seguindo a seguinte equação:

$$gene = gene + N(0, \sigma) \quad (4)$$

Passado o processo de mutação, a seleção da nova população é feita de modo elitista, utilizando os melhores N indivíduos, para a próxima geração.

## 2 Resultados

Nesta seção mostramos os resultados alcançados em cada abordagem da implementação do algoritmo.

### 2.1 Primeira abordagem

Para a estratégia ingênua, não houve convergência para o mínimo global em nenhuma das 30 tentativas. Tendo uma média de iterações até o ponto de parada de 7902 e um fitness médio geral de 17.874.

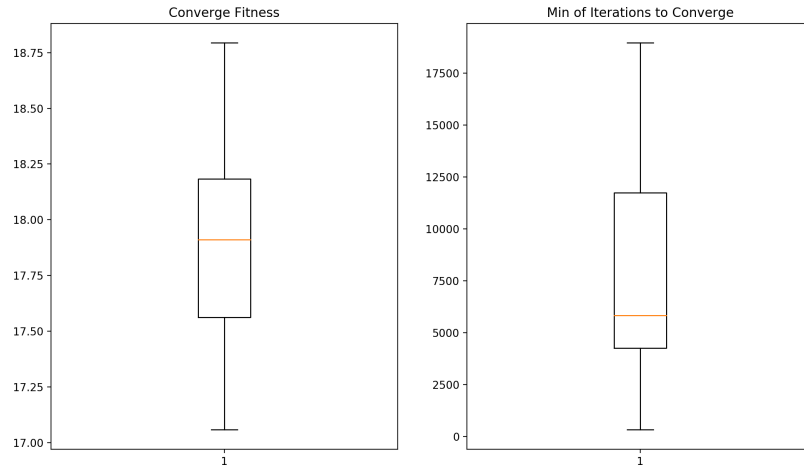


Figura 2 – Boxplot resultado estratégia ingênua

## 2.2 Segunda abordagem

Para a segunda estratégia, houve convergência para o mínimo global em todas as tentativas. Tendo uma média de iterações até o ponto de convergência de 5210 e um fitness médio geral de  $9.71e-15$ .

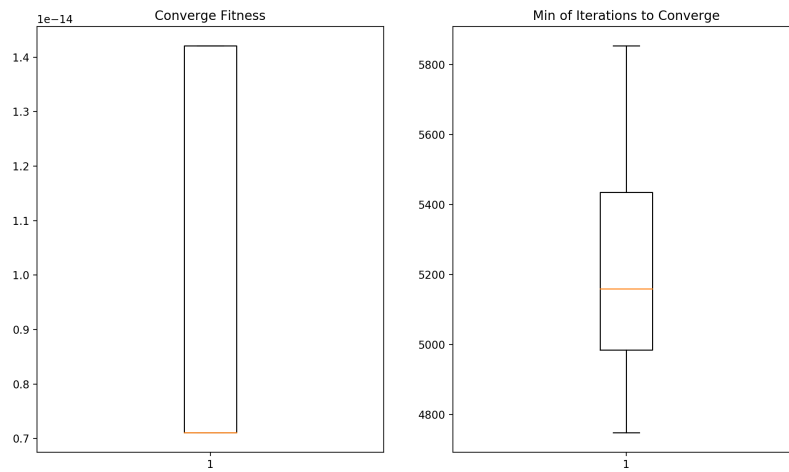


Figura 3 – Boxplot resultado segunda estratégia

## 2.3 Terceira abordagem

Para a terceira estratégia, houve convergência para o mínimo global em todas as tentativas. Tendo uma média de iterações até o ponto de convergência de 940 e um fitness médio geral de  $3.67e-15$ .

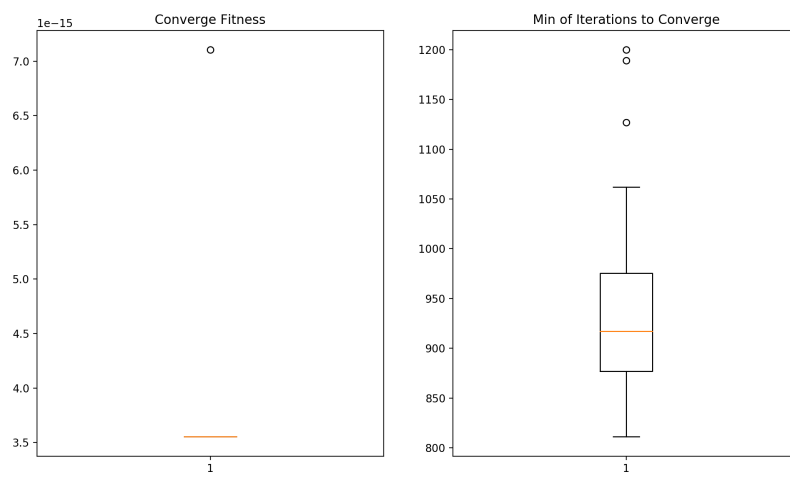


Figura 4 – Boxplot resultado terceira estratégia